Conceitos do projeto final

Risco de incêndio por município e dia. Material de estudo com tudo o que o projeto usa, explicado sem matemática e ligado aos números finais publicados no GitHub.

Como usar este material

- **Parte A (seções 1 a 9):** Etapa 1, a preparação dos dados.
- **Parte B (seções 10 a 17):** Etapas 2 e 3, os modelos e o resultado.
- **Parte C (seções 18 a 20):** como contar o projeto, perguntas prováveis com resposta e glossário.

Cada conceito vem em três camadas: a ideia, uma comparação do dia a dia (quadro verde) e onde aparece no seu projeto (quadro azul). O quadro amarelo marca um cuidado.

O mapa do projeto

Etapa 1	Etapa 2	Etapa 3
Juntar as bases, montar a grade, EDA (análise exploratória), 2 testes de hipótese, KPIs	3 modelos, métricas, custo em reais, plano de teste A/B	Optuna, SHAP, viés por região e bioma, boletim em texto, conclusão

A história em cinco frases

1. Brigadas e defesa civil precisam decidir todo dia onde deixar equipes de prontidão.
2. A base de queimadas só mostra onde já houve fogo. Os dias sem fogo, que ensinam o que é risco baixo, não aparecem: é o viés de sobrevivência.
3. Por isso montamos uma grade com os municípios em todos os dias, e o dia sem foco vale zero.
4. O modelo prevê, para cada município e dia, se o risco é Baixo, Médio ou Alto, usando só o que se sabia até a véspera. A régua mínima a vencer é a persistência: "o risco de hoje é o de ontem".
5. O modelo final vence a régua e custa R$ 19,0 milhões a menos, mas avisa 51,8 de cada 100 dias Alto, abaixo da meta de 60. A hipótese do projeto se confirma em parte.

OS QUATRO NÚMEROS PARA GUARDAR

Período de teste, de novembro de 2024 a fevereiro de 2025, modelo final contra a persistência: acerto geral 0,5677 contra 0,5490; avisos certos 56,8 contra 49,2; dias Alto avisados 51,8 contra 49,8; custo R$ 415,8 milhões contra R$ 434,8 milhões.

PARTE A: ETAPA 1

1 O problema, o alvo e os níveis raros

Classificação é prever uma categoria. Aqui são três, então é classificação multiclasse. Os níveis têm uma ordem (Baixo < Médio < Alto); por isso o alvo também é chamado de ordinal.

Um **foco** é um ponto de calor detectado por satélite, sinal de fogo na vegetação. Um **município-dia** é um município num dia: cada linha da base é um deles.

Nível	Regra	% dos município-dias
Baixo	nenhum foco de satélite polar	85,83%
Médio	1 a 3 focos	7,89%
Alto	4 ou mais focos	6,29%

As **features** são as colunas usadas para prever. O alvo se chama `nivel_risco`. A coluna `focos` é a base do alvo e nunca pode virar feature: seria dar a resposta.

COMPARAÇÃO

Um meteorologista que sempre diz "não vai chover" numa cidade seca acerta quase todo dia, e não serve para nada no dia da tempestade.

NO SEU PROJETO

Um modelo que diz "Baixo" para todo mundo acerta 85,83% das vezes e nunca avisa um incêndio. Por isso a acurácia não é a métrica principal.

Por que esses limites?

Baixo é o dia sem nenhum foco. Entre os dias com foco, a mediana (o valor do meio) é de 3 focos; o limite em 4 separa o fogo isolado (Médio) do dia com vários pontos queimando ao mesmo tempo (Alto), que é o que pede equipe de prontidão. Os dois níveis menores ficam acima de 5%, o que dá exemplos suficientes para o modelo aprender.

2 Viés de sobrevivência: o dado que falta

Na Segunda Guerra, o estatístico Abraham Wald analisou os aviões que voltavam de combate. Eles tinham buracos nas asas e na fuselagem. A conclusão certa foi blindar onde *não* havia buracos, porque os aviões atingidos ali não voltaram para entrar na estatística. **Viés de sobrevivência** é tirar conclusões só de quem "sobreviveu" ao filtro que gerou os dados.

NO SEU PROJETO

A base de queimadas só tem uma linha quando o satélite viu fogo. O `risco_fogo` do INPE parece altíssimo: 67,01% dos focos estão na faixa crítica (0,95 ou mais). Não é que o Brasil viva em risco crítico; é que o risco só é registrado onde já está queimando. A solução foi a grade: município × dia, com zero no dia sem foco. Esses zeros são os "aviões que não voltaram".

A RESSALVA HONESTA

"Nenhum foco detectado" não é o mesmo que "nenhum fogo". Nuvens e fogos pequenos escapam do satélite. O alvo mede o fogo visível por satélite.

3 Vazamento de dados

Vazamento é quando o modelo recebe uma informação que não existiria no momento da previsão. Ele parece ótimo no notebook e falha no uso real.

Coluna	Por que vaza	Decisão
`risco_fogo`, `dias_sem_chuva`, `precipitacao`	Só existem nas linhas em que houve foco. Se a coluna tem valor, já se sabe que houve fogo.	Fora das features.
`bioma`	A única fonte é a base de queimadas: o município sem nenhum foco ficaria com bioma vazio, o que entregaria "Baixo".	Só nos gráficos e no teste de viés.
histórico de focos	Se a janela incluísse o próprio dia, o modelo veria o fogo de hoje.	Janelas sempre terminam na véspera.
`focos`	É a base do alvo.	Nunca é feature.

> **COMPARAÇÃO**
> Prever se um restaurante vai lotar olhando a fila na porta. A fila só existe porque já lotou.

4 Juntar as bases

Granularidade e chave

Granularidade é o que cada linha representa. Cada base vem numa granularidade diferente, e o trabalho é levar todas para a mesma: um município num dia. A **chave** que liga as bases é `id_municipio` (o código IBGE) e, quando há data, `dia`.

Base	Cada linha é...	Como vira município × dia
Queimadas	um foco, num ponto, num horário	contar os focos por município e dia
MapBiomas	uma classe de solo num município num ano	proporção de cada grupo em 2021, igual em todos os dias
BDMEP 2025 + INMET 2024	uma hora numa estação	um valor por estação e dia; depois, a estação mais próxima que mediu

Tipos de junção

- **Junção cruzada (`CROSS JOIN`):** combina tudo com tudo. Foi assim que nasceu a grade: 5 566 municípios × 409 dias, antes de tirar os primeiros 30 dias.
- **Junção à esquerda (`LEFT JOIN`):** mantém todas as linhas da grade e traz a contagem de focos onde existir. Onde não existe, o vazio vira zero.
- **Junção interna (`JOIN`):** só as linhas que existem nos dois lados.
- **Empilhar (`UNION ALL`):** põe as linhas de uma tabela embaixo das de outra.

NO SEU PROJETO: AS BASES QUASE NÃO SE ENCONTRAM NO TEMPO

Queimadas: jan/2024 a 12/fev/2025. BDMEP fornecido: jan a jun/2025. Os dois coexistem por só 43 dias, em época de chuva. A solução foi completar o clima de 2024 com os dados históricos anuais do INMET, a mesma fonte, com 565 estações. O MapBiomas termina em 2021, e o uso do solo de 2021 entrou como aproximação de algo que muda devagar.

Ligar município e estação

Nem todo município tem estação meteorológica. A distância da sede até cada estação é calculada pela fórmula de **Haversine**, que mede a distância sobre a superfície da Terra (uma régua esticada sobre um globo, e não sobre um mapa plano).

- **Coordenadas dos municípios:** nenhuma base fornecida tinha. Vieram de uma base pública (`kelvins/municipios-brasileiros`, licença aberta MIT). Usar as coordenadas dos focos seria vazamento: o município sem fogo ficaria sem coordenada.
- **As 10 estações mais próximas, a até 400 km:** falha de sensor é comum, então um município não depende de uma estação só.
- **Cada medida vem da estação mais próxima que mediu aquilo naquele dia.** Uma estação distante só entra quando as próximas falharam. Metade dos municípios tem estação a até 33,8 km, e 99,7% têm uma a até 150 km.
- **Linhas sem nenhum clima saem:** 3 103 linhas (0,15%) e 0,11% dos focos, listadas em `linhas_sem_clima_por_municipio.csv`. Quatro municípios do Amazonas saíram por inteiro.

POR QUE 400 KM, E NÃO 150

O limite foi escolhido pela perda. Com 150 km, as linhas sem clima levariam 14% dos focos do país, incluindo municípios como São Félix do Xingu, que está entre os que mais queimam. Com 300 km, 2,4%. Com 400 km, 0,11%. Só 1,55% dos município-dias usam clima de mais de 150 km, e a coluna `distancia_estacao_km` avisa o modelo disso.

O DICIONÁRIO ESTAVA ERRADO

O dicionário da TripleTen fala em 7 classes no MapBiomas, mas o arquivo tem 28 códigos, os da legenda oficial da Coleção 7 (3 = formação florestal, 15 = pastagem, 39 = soja, 24 = área urbanizada). Conferir o dado contra o dicionário é pensamento crítico.

SQL, DuckDB e Parquet

A junção foi escrita em **SQL**, a linguagem usada para consultar tabelas. O **DuckDB** roda SQL direto sobre arquivos CSV grandes, sem banco de dados instalado. A base final é salva em **Parquet**, um formato compacto: 9 MB. A consolidação tem 12 passos, e duas execuções seguidas geram exatamente o mesmo arquivo.

5 Satélites e a contagem de focos

- **Órbita polar** (NOAA-20, NOAA-21, NPP, AQUA, TERRA, METOP): passam sobre cada região poucas vezes por dia.
- **Geoestacionários** (GOES-16, MSG-03): ficam "parados" sobre o mesmo ponto e fotografam a cada poucos minutos.

NO SEU PROJETO

O GOES-16 registra 30,59 focos por município-dia com fogo, contra 10,36 do NOAA-20: ele conta o mesmo incêndio várias vezes. A contagem usa só satélites polares e ignora os 4 focos duplicados. O INPE faz algo parecido nas séries históricas, com um único satélite de referência (o AQUA, à tarde); sozinho, ele veria fogo em só 64 777 município-dias, um terço do que o NOAA-20 vê.

6 Engenharia de features

Engenharia de features é criar colunas que ajudam o modelo a enxergar o padrão.

Família	Colunas	Ideia
Histórico	`focos_ontem`, `focos_7d`, `focos_30d`, `dias_com_foco_30d`	O fogo de ontem e da última semana avisa o de hoje.
Calendário	`mes`, `dia_do_ano`	O fogo muda com a época do ano.
Uso do solo	`pct_floresta`, `pct_pastagem` ... (7 grupos), `area_km2`	O tipo de paisagem muda o risco.
Mudança no solo	`perda_nativa_5a`	Queimada é uma forma de abrir área.
Clima da véspera	`umidade_min_ontem`, `temp_max_ontem`, `chuva_ontem`, `vento_ontem`, `chuva_7d`, `distancia_estacao_km`	Ar seco, calor e semana sem chuva antecipam o fogo.
Lugar	`sigla_uf`	O estado resume a região do país.

Defasagem (lag) é o valor da mesma coluna em dias anteriores. **Janela móvel** é a soma ou contagem dos últimos N dias. As duas olham só para trás.

NO SEU PROJETO

Os primeiros 30 dias foram retirados, porque não têm 30 dias de passado para calcular `focos_30d`. Por isso a grade final começa em 31/01/2024. Um valor diário de clima só vale se a estação mediu pelo menos 18 das 24 horas. Os poucos vazios restantes (0,13% ou menos em cada coluna) não foram preenchidos na base: preencher com a média agora usaria o futuro. O preenchimento é feito dentro do treino.

7 Estatística descritiva, outliers e correlação

A ferramenta mais útil é a **taxa por grupo**: em cada grupo, que % dos município-dias é Alto. Para variáveis numéricas, dividimos os municípios em **quintis**: 5 grupos do mesmo tamanho, do menor valor ao maior.

Achado	Número
Setembro contra abril	15,38% contra 1,21% de dias Alto
Mais de 10 focos ontem contra nenhum	76,35% contra 1,91% de dias Alto
Municípios mais florestados contra menos	12,97% contra 2,46%
Mais perda de vegetação nativa contra menos	8,14% contra 5,34%
Estados: Roraima, Pará, Acre	48,20%, 26,05% e 24,71%
Biomas: Amazônia e Cerrado	53,44% e 28,45% dos focos
Umidade mínima da véspera, antes de dia Alto contra Baixo	32,60% contra 47,72%
Chuva nos 7 dias anteriores, antes de dia Alto contra Baixo	8,45 mm contra 30,02 mm

CUIDADO: VARIÁVEL ESCONDIDA

"Mais floresta, mais fogo" parece estranho. Mas os municípios mais florestados são, em boa parte, os da Amazônia, que também são os maiores: município maior tem mais área para pegar fogo. Quando duas coisas andam juntas por causa de uma terceira, essa terceira é uma **variável de confusão**. O DF também engana: aparece em segundo lugar (44,33%), mas é um único município, e grande.

Outliers

Outliers são valores muito fora do padrão. Há município-dias com até 10 620 focos, contra mediana de 3 nos dias com fogo. São incêndios grandes e reais, então ficam. Como o alvo agrupa tudo a partir de 4 focos em "Alto", esses extremos não distorcem o alvo.

Correlação de Spearman

A **correlação** mede, de −1 a 1, o quanto duas colunas andam juntas. A de **Spearman** compara só a ordem dos valores: foi escolhida porque o alvo é ordenado e porque não se deixa levar pelos outliers. Foi calculada numa amostra de 300 mil município-dias.

NO SEU PROJETO

As mais ligadas ao risco: `focos_ontem` (0,492), `focos_7d` (0,469), `dias_com_foco_30d` (0,450) e `area_km2` (0,304), seguidas pelo clima: `umidade_min_ontem` (−0,245), `temp_max_ontem` (0,241) e `chuva_7d` (−0,229). Nenhuma passa de 0,7, então não há coluna "espelho" do alvo. As features de histórico andam muito juntas entre si (**multicolinearidade**), o que atrapalha a leitura dos pesos da regressão logística, mas não as árvores.

8 Testes de hipótese

Um teste de hipótese responde: "essa diferença é real ou pode ser sorte?".

Peça	O que é
H0	"Não há diferença." É o que o teste tenta derrubar.
H1	"Há diferença."
α (alfa)	O risco de errar aceito, decidido antes do teste: 5%.
p-valor	Se H0 fosse verdade, a chance de ver uma diferença tão grande quanto a observada.
Decisão	p-valor < α rejeita H0. Caso contrário, não rejeita, o que não prova que H0 é verdade.

COMPARAÇÃO

Uma moeda dá 10 caras seguidas. Se fosse honesta, isso aconteceria cerca de 1 vez em 1 000. Como é raro demais, desconfiamos da moeda. O p-valor é esse "1 em 1 000".

Teste 1, qui-quadrado: o fogo de ontem

O **qui-quadrado** compara contagens de categorias com o que se esperaria se não houvesse relação.

RESULTADO

Com foco ontem, a chance de foco hoje é 53,16%; sem foco ontem, 7,73%, cerca de 7 vezes menos. Qui-quadrado = 434 924,8, p-valor < 0,001: rejeitamos H0. O histórico de focos é a base do modelo.

Teste 2, t de Welch: a véspera seca

O **teste t** compara médias de um número entre dois grupos. O de **Welch** não supõe que os dois grupos tenham a mesma variação.

RESULTADO

Em 2 104 783 município-dias: umidade mínima média de 35,82% antes dos dias com foco, contra 47,72% antes dos dias sem foco. p-valor < 0,001: rejeitamos H0.

E se for só o lugar? O teste pareado

A comparação acima mistura regiões diferentes. Para separar o efeito do dia do efeito do lugar, ela é refeita dentro de cada município. Cada município vira um par de números, e o **teste t pareado** compara os pares.

COMPARAÇÃO

Para saber se um remédio baixa a pressão, é melhor medir a mesma pessoa antes e depois: cada um é o seu próprio controle.

RESULTADO

Em 99,0% dos 4 557 municípios com dias suficientes, a véspera dos dias com foco é mais seca, com 12,16 pontos a menos de umidade na mediana (p < 0,001). No mesmo município, o fogo aparece depois dos dias mais secos.

CORRELAÇÃO NÃO É CAUSA

O teste mostra que ar seco e fogo andam juntos, não que um causa o outro (o próprio fogo também seca o ar ao redor). Para o modelo isso basta: ele precisa de sinais que antecipem o risco.

9 A referência mínima e os KPIs

O **modelo de referência** (baseline) é uma régua estatística mínima: se o modelo não passar dela, não vale a complexidade. É um piso, não uma descrição de como o trabalho é feito na prática.

NO SEU PROJETO: A PERSISTÊNCIA

A régua é a **persistência**: prever que o risco de hoje é o mesmo de ontem. Na base inteira, ela acerta bem o Baixo (F1 0,9226) e razoavelmente o Alto (F1 0,5567), mas erra muito o Médio (F1 0,2217). O F1 macro dela é 0,5670.

CUIDADO COM A FRASE

A persistência não é "o que uma brigada faria sem modelo". Na prática, as equipes costumam usar a previsão diária de risco de fogo do INPE, a previsão do tempo e o conhecimento do território. A régua ideal seria a previsão do INPE, mas na base fornecida ela só existe nos dias em que já houve fogo.

O que queremos saber	Persistência na base inteira	Meta do modelo
Dias Alto avisados (recall do Alto)	56 de cada 100	pelo menos 60 de cada 100
Avisos certos (precisão do Alto)	56 de cada 100	pelo menos 55 de cada 100
Acerto geral (F1 macro)	0,5670	acompanhado; piso de 0,55
Custo: equipes nos dias avisados + dias Alto sem equipe	medido na Etapa 2	menor que o da persistência

As metas foram fixadas antes da modelagem da Etapa 2. Um teste rápido, fora da entrega, serviu só para não prometer um número impossível, e está declarado no projeto.

Por que F1 macro? Ele é a média simples do F1 dos três níveis, com o mesmo peso para cada um. Assim, o modelo não "ganha" só acertando o Baixo. O F1 ponderado daria peso pelo tamanho e deixaria o Baixo mandar.

PARTE B: ETAPAS 2 E 3

10 Divisão dos dados por tempo

O modelo vai ser usado no futuro. Por isso a divisão é por tempo. Sortear as linhas misturaria o futuro no treino.

Parte	Período	Linhas	% Alto	Para que serve
Treino	31/01 a 30/09/2024	1 355 812	5,94	o modelo aprende (as aulas)
Validação	outubro de 2024	172 316	12,41	escolher modelo, ajustes e cortes (o simulado)
Teste	01/11/2024 a 12/02/2025	578 283	5,29	a nota final (a prova)

Os modelos aprendem com uma amostra aleatória de 400 mil linhas do treino; validação e teste são usados inteiros.

> **DOIS LIMITES QUE VÊM DA BASE**
> O teste cai na época de chuva, com poucos dias Alto, e o treino não tem nenhum dia de outubro a dezembro, porque só há um ano de dados. Para as colunas de calendário, esses meses são novos, e as árvores os tratam como setembro, o último mês conhecido. A nota de janeiro e fevereiro sofre com isso.

> **COMPARAÇÃO**
> Avaliar um vendedor de sorvete só pelo inverno. A nota fica baixa, mas não só por culpa dele.

11 Os três modelos

Modelo	Como pensa	Comparação
Regressão logística	Dá um peso para cada feature e transforma a soma em probabilidade, uma para cada nível.	Uma ficha de pontuação: +10 por fogo ontem, +3 por ser setembro.
Floresta aleatória	Centenas de árvores de decisão, cada uma com uma amostra diferente, que votam no fim.	Perguntar a 100 pessoas experientes e seguir a maioria.
LightGBM	Árvores em sequência, cada uma corrigindo os erros das anteriores (boosting).	Um aluno que refaz só as questões que errou.

Árvore de decisão é uma sequência de perguntas sim/não ("houve fogo ontem?", "é setembro?") que termina numa previsão. Os três usam `class_weight='balanced'`: dão mais peso aos erros nos níveis raros. Sem isso, tenderiam a dizer "Baixo" quase sempre.

Os vazios são preenchidos dentro de um **Pipeline**, uma linha de montagem que aprende os ajustes só no treino e os aplica igual na validação e no teste.

12 Métricas e notas de corte

Um **dia Alto** é um município-dia de nível Alto. Um **aviso** é um município-dia que o método chamou de Alto.

Métrica	Pergunta que responde
Acurácia	Que fração dos dias foi acertada? Engana quando um nível é raro.
Precisão do Alto (avisos certos)	Dos dias que o método chamou de Alto, quantos foram Alto?
Recall do Alto (dias Alto avisados)	Dos dias que foram Alto, quantos o método avisou?
F1	Uma nota de 0 a 1 que só fica alta se precisão e recall forem altos.
F1 macro (acerto geral)	A média do F1 dos três níveis, com peso igual.
AUC-ROC	De 0,5 (sorteio) a 1 (perfeito), o quanto o modelo ordena bem os dias, antes de qualquer corte.

A **matriz de confusão** cruza o que aconteceu com o que o modelo disse; a diagonal são os acertos.

A **nota de corte** é a probabilidade a partir da qual o dia vira aviso. Regra usada: se a probabilidade de Alto passa do corte do Alto, é Alto; senão, se a de Médio passa do corte do Médio, é Médio; senão, é Baixo. Os cortes são escolhidos só na validação.

> **PRECISÃO CONTRA RECALL**
> Baixar o corte avisa mais dias, com menos avisos certos. Subir faz o contrário. Pôr equipe em todo município todo dia dá recall de 100% e precisão péssima. Escolher o equilíbrio é uma decisão de custo.

Resultado da Etapa 2, no teste

	F1 macro	Avisos certos	Dias avisados	F1 do Alto	AUC
Persistência	0,5490	49,2	49,8	0,4951	não tem
Regressão logística	0,5649	58,7	49,9	0,5393	0,8550
Floresta aleatória	0,5644	57,3	52,7	0,5492	0,8559
LightGBM sem ajustes	0,5603	53,2	47,8	0,5036	0,8526

> **NO SEU PROJETO**
> A regressão logística foi a escolhida da Etapa 2, pelo maior acerto geral na validação (0,5794, contra 0,5790 da floresta e 0,5762 do LightGBM). A diferença é pequena, e o notebook diz isso. Ela vale em municípios que nunca viu (1 112 sorteados: F1 do Alto de 0,5497 contra 0,5037) e nos 3 meses de mais fogo. Em janeiro e fevereiro, fica abaixo da persistência. Nos municípios pequenos, também.

13 Transformar o modelo em reais

Premissa	Valor	Fonte
Equipe por dia	R$ 1.032	salários do chamamento do Prevfogo, o centro de combate a incêndios florestais do Ibama (1 chefe + 4 brigadistas, 22 dias, o dobro para encargos e transporte)
Prejuízo por hectare	R$ 5.250	R$ 14,7 bilhões ÷ 2,8 milhões de hectares, da Confederação da Agricultura e Pecuária do Brasil (CNA); a divisão é do projeto
Área a mais sem equipe	5 hectares	**sem fonte:** é a premissa mais incerta

Conta: custo total = avisos Alto × custo da equipe + dias Alto sem aviso × hectares × R$ 5.250. Regressão logística: R$ 429,2 milhões, contra R$ 434,8 milhões da persistência. Cada 10% a menos de dias Alto sem aviso vale R$ 40,2 milhões.

ANÁLISE DE SENSIBILIDADE

Como as premissas são estimativas, a conta é refeita em 15 cenários, variando hectares e custo da equipe. A economia é positiva nos 15. Assim, nenhum número inventado sustenta sozinho a recomendação.

O CORTE PELO CUSTO

Se o corte for escolhido pelo menor custo, ele cai para 0,15: o modelo avisa 91 de cada 100 dias Alto, com só 20 de cada 100 avisos certos, e o custo vai a R$ 215,5 milhões. A meta de recall é, em boa parte, uma escolha de custo. Quem decide é o gestor, conforme quanto custa de fato um incêndio sem resposta.

14 Plano de teste A/B

Um **teste A/B** sorteia grupos, um com a novidade e outro sem, para medir o efeito. Aqui entra só o plano; o teste não é executado.

Elemento	No plano
Controle (A)	Regiões que posicionam as equipes como hoje.
Tratamento (B)	Regiões que usam, além disso, a lista diária do modelo.
H0 e H1	H0: a área queimada por foco é igual nos dois grupos. H1: é menor no grupo B.
Sorteio por grupo	Grupos de municípios vizinhos, não municípios soltos: o fogo atravessa fronteiras, e uma equipe do B ajudaria um vizinho do A (**contaminação**).
Pares parecidos	Grupos da mesma região com histórico parecido formam pares; cada par tem um em A e outro em B.
Métrica principal	Área queimada por foco detectado.
Métricas de proteção	Custo de prontidão e dias Alto sem equipe: não podem piorar.
Nota de corte	Fixada antes do início e mantida até o fim.
Duração	Uma estação seca inteira (agosto a outubro).
Decisão	Adota-se o modelo se H0 for rejeitada e as métricas de proteção não piorarem, sem olhar o resultado no meio.
Ética	O grupo A não perde nada; o modelo só se soma à estratégia no grupo B.

Poder estatístico é a chance de o teste enxergar uma diferença que existe. O tamanho é calculado antes, com α de 5% e poder de 80%.

15 Otimização com o Optuna

Parâmetros o modelo aprende sozinho; **hiperparâmetros** são ajustes escolhidos antes do treino (quantas árvores, tamanho, velocidade de aprendizado). O **Optuna** procura a melhor combinação, usando o resultado de cada tentativa para escolher a próxima. **Sobreajuste** é o modelo decorar o treino e ir mal em dado novo; a **regularização** é um freio contra isso.

COMPARAÇÃO

Acertar o ponto de um bolo: depois de alguns bolos, você já sabe para que lado ajustar o forno.

NO SEU PROJETO

Foram 30 tentativas com o LightGBM, pelo F1 macro na validação. Ele subiu de 0,5762 para 0,5874 e passou a regressão logística (0,5794), então **o LightGBM otimizado virou o modelo final**. Venceu com 700 árvores, 49 folhas e taxa de aprendizado de 0,011. O número de árvores ficou no máximo testado.

Por que otimizar o LightGBM, e não a regressão logística? O enunciado sugere o LightGBM para a otimização, e ele tem muito mais ajustes para testar. O critério é o mesmo da Etapa 2: se passar da regressão logística na validação, vira o modelo final.

Um corte para cada tamanho de município

Municípios pequenos quase não têm dias Alto, e um corte único quase nunca os avisa. Por isso cada faixa de área ganhou seu corte, de 0,35 a 0,55, escolhido na validação.

Faixa	Corte único	Corte por faixa	Persistência
1 (menores)	0,0281	0,1546	0,1590
2	0,0621	0,1114	0,2212
3	0,2533	0,3573	0,3155
4	0,4817	0,5090	0,4583
5 (maiores)	0,6327	0,6346	0,5966

O corte por faixa supera a persistência nas 3 maiores e fica quase igual na menor, mas ainda perde na faixa 2.

ESCOLHA DECLARADA

Na validação, o corte único tinha acerto geral maior (0,5874 contra 0,5821). O corte por faixa foi adotado por um motivo de uso: não abandonar municípios pequenos. A ideia nasceu de uma tabela do teste, e isso também está declarado, porque a melhora pode estar um pouco otimista.

16 Explicabilidade com o SHAP

O **SHAP** responde: "para este município neste dia, quanto cada coluna empurrou o modelo a favor ou contra o risco Alto?". Somando os empurrões em 5 000 município-dias do teste, sabemos quais colunas mais pesam.

COMPARAÇÃO

Dividir a conta do restaurante pelo que cada um pediu, e não em partes iguais.

Coluna	Peso	O que quer dizer
`focos_30d`	23,7%	lugar que vem queimando tende a seguir queimando
`umidade_min_ontem`	9,0%	quanto mais seco o ar, maior o risco
`chuva_7d`	8,9%	quanto menos chuva na semana, maior o risco

As quatro colunas de histórico somam 44,8%, e umidade, chuva de 7 dias e chuva de ontem somam 24,0%. Isso confirma os dois testes de hipótese da Etapa 1.

SHAP NÃO É CAUSA

Ele mostra no que o modelo se apoia, e não o que provoca o fogo.

17 Viés e boletim em texto

Viés aqui é o modelo tratar pior algum grupo. A base não tem pessoas, então não há gênero nem idade; os grupos que importam são os lugares, porque é o lugar que deixa de receber equipe.

Grupo (no teste)	Dias Alto	Dias avisados, de cada 100	F1 modelo	F1 persistência
Norte	7 583	73	0,6740	0,6443
Nordeste	19 418	50	0,5240	0,4819
Centro-Oeste	1 814	27	0,3384	0,3301
Sul	636	12	0,1687	0,1772
Sudeste	1 132	6	0,1027	0,1623
Amazônia	9 891	75	0,6995	0,6671
Mata Atlântica	3 014	9	0,1334	0,1722

NO SEU PROJETO

O viés é grande. A causa provável é a época do ano e a falta de exemplos: de novembro a fevereiro, é chuva em boa parte dessas regiões. Em outubro, o recall sobe de 6 para 49 no Sudeste e de 27 para 67 no Centro-Oeste. O Sul fica baixo nos dois períodos (12 e 12). Mesmo com a causa explicada, o efeito é real. Recomendação: em Sudeste e Sul, o modelo entra só como apoio, e o recall por região é acompanhado todo mês.

Distância até a estação: os 128 municípios com estação em geral a mais de 150 km não vão pior (recall 59), e os três grupos superam a persistência. Isso não prova o valor do clima, só que não há sinal de prejuízo.

Boletim com regra fixa, sem LLM

Uma **LLM** é um modelo de linguagem, como o ChatGPT ou o Claude. O enunciado a traz como opcional. O projeto gera o boletim com uma frase padrão, preenchida com o nível e os 3 fatores do SHAP:

EXEMPLO REAL

"Portel (PA), 02/11/2024: risco ALTO. O que mais pesou: focos ontem: 1073; focos nos últimos 30 dias: 16163; focos nos últimos 7 dias: 5752. Manter equipe de prontidão."

Motivos: nada é inventado (**alucinação** é a LLM criar um fato que não estava nos dados), não há chave de serviço pago num repositório público e o resultado é reproduzível. O boletim não mostra porcentagem, porque com o peso maior nos níveis raros a "probabilidade" serve para ordenar os dias, e não é uma chance real.

PARTE C: PARA EXPLICAR O PROJETO

18 O resultado final e a hipótese

Hipótese: com o que se sabe até a véspera, um modelo avisa os dias de risco Alto melhor do que a persistência e reduz o custo de posicionar equipes. **Resposta: confirmada em parte.**

Meta	Persistência	Modelo final	
Acerto geral ≥ 0,55	0,5490	0,5677	**sim**
Avisos certos ≥ 55 de cada 100	49,2	56,8	**sim**
Dias Alto avisados ≥ 60 de cada 100	49,8	51,8	**não**
Custo menor que o da persistência	R$ 434,8 mi	R$ 415,8 mi	**sim, R$ 19,0 mi (4,4%)**

Em novembro, mês do teste com mais fogo, o modelo atinge as duas metas do Alto (60,3 dias avisados e 62,2 avisos certos). AUC do modelo final: 0,8619.

> **MARGEM DE ERRO (CONFERÊNCIA FEITA FORA DO REPOSITÓRIO)**
> Sorteando municípios 1 000 vezes, com os 5 hectares fixos: economia de R$ 13,1 a 25,6 milhões, dias avisados de 49,7 a 54,0 e avisos certos de 55,4 a 58,1. O ganho sobre a persistência foi positivo em todos os sorteios, e a meta de 60 não foi atingida em nenhum.

Para quem decide: vale usar o modelo como lista diária de prioridade, sobretudo nos meses de mais fogo, no Norte e no Nordeste. Ele não substitui a prática das equipes. O gestor escolhe o corte. A economia é uma estimativa, e só o teste A/B pode comprovar.

Próximos passos fora do escopo: mais anos de dados, fogo nos municípios vizinhos, previsão do tempo do próprio dia e risco em focos por km². Com um ano só, um resultado mais robusto depende de mais dados, não de mais ajustes.

19 Perguntas prováveis sobre as suas decisões

"Por que não usou o risco_fogo do INPE como alvo?"

Porque ele só existe onde já há fogo. Um modelo treinado nele aprenderia "como é o risco quando já está queimando". O alvo pelo número de focos, com os dias sem fogo, mede a chance de pegar fogo.

"Por que montar uma grade com 2,1 milhões de linhas?"

Por causa do viés de sobrevivência. Os dias sem fogo são os exemplos de risco baixo.

"Por que só satélites polares?"

Porque os geoestacionários fotografam a cada poucos minutos e contam o mesmo incêndio várias vezes.

"Por que o limite do Alto em 4 focos?"

Fica perto da mediana dos dias com fogo (3 focos), separa o fogo isolado do dia com vários pontos e deixa os dois níveis menores acima de 5%.

"Por que baixou dados que não estavam na base fornecida?"

O BDMEP só cobre 2025, e as bases coexistem por 43 dias. Os dados do INMET são a mesma fonte, públicos, e completam 2024. As coordenadas eram a única forma de ligar município e estação sem usar os focos.

"Por que estações a até 400 km? Isso não é longe demais?"

Cada medida vem da estação mais próxima que mediu; a distante só entra se as próximas falharam, e só 1,55% dos município-dias usam mais de 150 km. Com 150 km, as linhas sem clima levariam 14% dos focos do país. A distância entra como coluna, e o teste de viés não mostra prejuízo.

"E as linhas sem clima?"

Foram retiradas 3 103 (0,15%), porque deixariam o modelo só com histórico e dados fixos. A lista está no repositório.

"Por que a divisão por tempo?"

Porque o modelo vai prever o futuro. Sortear colocaria dias de setembro no treino e dias vizinhos no teste.

"Por que a Etapa 2 escolheu regressão logística e o final é LightGBM?"

O critério é o mesmo: maior F1 macro na validação. Sem ajustes, venceu a logística (0,5794). Otimizado, o LightGBM passou (0,5874).

"Se as metas principais são sobre o Alto, por que escolher por F1 macro?"

Porque o modelo precisa separar os três níveis, e o F1 macro cobre isso. A diferença fica registrada no notebook: só pelo F1 do Alto na validação, a floresta ficava à frente (0,6407), e o LightGBM otimizado com corte único chega a 0,6374.

"Por que a meta de 60 não foi atingida?"

Dá para atingir baixando o corte, mas a precisão cai: com corte 0,40, são 61,4 dias avisados e 47,6 avisos certos. Mudar agora seria ajustar depois de ver a prova. Em novembro, as duas metas são atingidas; o período de teste inclui janeiro e fevereiro, com poucos dias Alto.

"As metas foram mesmo decididas antes?"

Antes da modelagem da Etapa 2. Houve um teste rápido, com um modelo simples, só para não prometer um número impossível. Está declarado no projeto, e elas não mudaram depois.

"Por que usou o corte por faixa, se a validação preferia o único?"

Por um motivo de uso: não abandonar municípios pequenos. A escolha está declarada, com o cuidado de que a ideia veio de uma tabela do teste.

"Por que não usou LLM?"

Era opcional. A regra fixa não inventa nada, não precisa de chave paga em repositório público e dá sempre o mesmo resultado.

"A economia de R$ 19 milhões é real?"

É uma estimativa, porque depende dos 5 hectares, sem fonte. Ela é positiva nos 15 cenários, de R$ 4,7 a R$ 69,3 milhões. Só o teste A/B comprovaria.

"O modelo tem viés?"

Tem, por região: 73 de cada 100 dias Alto no Norte e 6 no Sudeste. A causa provável é a época do ano e a falta de exemplos. No Sudeste e no Sul, ele entra só como apoio.

"Por que não acrescentou mais bases?"

O projeto ficou no escopo da entrega. O próximo passo natural seria mais anos de focos e clima, e o período depois de fevereiro de 2025 como prova nova.

20 Glossário de bolso

Termo	Em uma linha
Alvo	A coluna a prever: `nivel_risco`.
Feature	Coluna usada para prever.
Foco	Ponto de calor detectado por satélite.
Município-dia	Um município num dia; uma linha da base.
Dia Alto / aviso	Município-dia de nível Alto / município-dia que o método chamou de Alto.
Multiclasse / ordinal	Mais de duas categorias / categorias com ordem.
Viés de sobrevivência	Concluir só a partir de quem passou pelo filtro que gerou os dados.
Grade	Municípios × dias, com zero onde não houve foco.
Vazamento	Informação que não existiria na hora da previsão.
Granularidade / chave	O que cada linha representa / a coluna que liga duas bases.
Haversine	Fórmula da distância sobre a superfície da Terra.
CROSS / LEFT / INNER JOIN	Tudo com tudo / mantém a esquerda / só o que existe nos dois lados.
Parquet	Formato de arquivo compacto para tabelas grandes.
Órbita polar / geoestacionário	Passa poucas vezes / fica parado e fotografa sem parar.
Defasagem / janela móvel	Valor de dias anteriores / soma dos últimos N dias.
Quintil	Cada um dos 5 grupos do mesmo tamanho.
Outlier	Valor muito fora do padrão.
Variável de confusão	A terceira variável que faz duas outras andarem juntas.
Spearman	Correlação que compara só a ordem dos valores.
Multicolinearidade	Features quase iguais entre si.
H0 / H1 / p-valor / α	Sem diferença / com diferença / chance de ver isso se H0 fosse verdade / risco aceito (5%).
Qui-quadrado / t de Welch / t pareado	Testa contagens / médias de dois grupos / pares da mesma unidade.
Persistência	Prever que hoje será igual a ontem. Um piso, não a prática das brigadas.
Treino / validação / teste	As aulas / o simulado / a prova.
Pipeline	Linha de montagem que aprende os ajustes só no treino.
Boosting	Árvores em sequência, cada uma corrigindo a anterior.
Nota de corte	Probabilidade a partir da qual o dia vira aviso.
Matriz de confusão	Tabela que cruza o previsto com o real.
Precisão / recall	Avisos certos / dias Alto avisados.
F1 / F1 macro	Junta precisão e recall / média do F1 dos níveis.
AUC-ROC	O quanto o modelo ordena bem, de 0,5 a 1.
Hiperparâmetro	Ajuste escolhido antes do treino; o Optuna procura o melhor.
Sobreajuste / regularização	Decorar o treino / o freio contra isso.
SHAP	Quanto cada coluna empurrou a previsão.
Viés (do modelo)	Errar mais para um grupo.
Contaminação (A/B)	Quando o tratamento de um grupo afeta o outro.
Poder estatístico	Chance de enxergar uma diferença que existe.
Alucinação	Quando a LLM inventa um fato.